Analisi del rischio di corruzione negli appalti italiani

I bigoli in salsa
Calori Dakota Davide, Fabris Luca

Introduzione

Il settore degli appalti pubblici in Italia è storicamente legato a un problema di corruzione e infiltrazioni mafiose. Il principale organo di controllo e di prevenzione è l'Autorità nazionale anticorruzione (ANAC), che fornisce numerosi strumenti tra cui alcune dashboard, numerosi dataset e un sistema di indicatori di rischio corruttivo studiati per la rilevazione di possibili anomalie.

Tuttavia, anche a causa della difficoltà intrinseca del problema, esistono pochi studi statistici che verifichino in modo solido l'associazione tra i risultati degli indicatori e l'individuazione effettiva dei casi di corruzione. Infatti, una delle maggiore limitazioni di un'analisi di questo tipo è la mancanza generale di dati contenenti informazioni sull'effettiva presenza della corruzione in casi presenti o passati, che potrebbero agire da variabile risposta in studi statistici di previsione del rischio; per questo, risulta più appropriato focalizzarsi su analisi di tipo non supervisionato, ossia senza conoscere lo stato effettivo di corruzione. Ad esempio, agenti dell'ANAC hanno provato ad affrontare il problema sfruttando metodi di analisi fattoriale [4]; il loro lavoro risente però di diverse criticità, tra cui l'alto numero di osservazioni scartate per l'impossibilità di calcolare tutti gli indicatori e la sostanziale mancanza di strumenti utilizzabili da chi indaga.

Il nostro lavoro affronta il problema tramite un approccio non supervisionato di anomaly detection, che si traduce in metodi statistici e di machine learning per l'analisi del rischio di corruzione rispetto a ciascuna stazione appaltante. Tutti codici per l'analisi sono presenti nella repository `analisi-corruzione-appalti` su Github.

Nel paragrafo *Dataset e preprocessing* ci siamo occupati della costruzione del dataset di partenza relativo ai bandi di appalto dal 2011 al 2025, scaricando alcuni dataset pubblici dal sito web ufficiale dell'ANAC e incrociandone le informazioni; questi dati sono stati poi sottoposti ad alcune preliminari operazioni di preprocessing per poter procedere con le successive analisi.

Successivamente, nel paragrafo *Calcolo delle red flag* abbiamo utilizzato il dataset dei bandi per calcolare alcuni indicatori di rischio per ogni stazione appaltante sviluppati dall'ANAC, applicando le procedure ufficiali per la loro costruzione; a questi abbiamo deciso di affiancare altre variabili per descrivere alcune informazioni importanti che gli indicatori non considerano. In questa fase mostriamo anche la gestione dei dati mancanti e la loro imputazione.

Il paragrafo *Metodi* è dedicato alla descrizione dei metodi di anomaly detection per l'elaborazione degli indicatori e per la valutazione del rischio di corruzione.

Infine, all'interno del paragrafo *Risultati e interpretazioni* presentiamo i risultati dell'analisi, utilizzando i modelli per rilevare le stazioni appaltanti più anomale e per capire l'influenza degli indicatori sul rischio di anomalia tramite valori SHAP.

Dataset e preprocessing

La prima fase del lavoro si è focalizzata sulla costruzione della base dati necessaria per

il calcolo degli indicatori di rischio. A tal fine, sono state integrate diverse fonti di dati pubblicamente disponibili nel portale ufficiale dell'ANAC [6], scaricate in data 27/02/2026, con l'obiettivo di consolidare in un unico dataset tutte le informazioni utili alla successiva creazione degli indicatori.

Metodologia e Preparazione dei Dati

Il fulcro dell'integrazione è rappresentato dal dataset dei Bandi CIG, di cui sono stati automaticamente estratti i record relativi al periodo compreso tra il 2011 e il 2025 tramite il relativo codice python. Tale risorsa è stata utilizzata come tabella principale di partenza, alla quale sono stati collegati gli altri set di dati rilevanti tramite operazioni di left join sulle chiavi identificative indicate nella documentazione [2].

In particolare, a ciascun bando sono state associate le informazioni riguardanti la stazione appaltante, le aggiudicazioni, gli aggiudicatari, le varianti in corso d'opera, la conclusione dei contratti, il quadro economico e i partecipanti, i cui dettagli tecnici sono consultabili sul sito dell'ANAC [5]. Grazie a questa integrazione, è stato possibile accedere a variabili fondamentali, quali codici identificativi, denominazioni, date, importi e varie altre caratteristiche procedurali, che costituiscono la base per la costruzione degli indicatori di rischio descritti nel paragrafo successivo.

Criteri di esclusione e pulizia dei dati

Alcune fonti informative sono state escluse dal processo di integrazione per ragioni specifiche. Il dataset relativo agli Smart CIG non è stato considerato sia per motivi normativi, legati al superamento di tale strumento nei nuovi regolamenti, [3], sia per motivi computazionali, poiché la sua elevata numerosità avrebbe costretto a ridurne la quantità utilizzata ad una piccola percentuale per poter mantenere contenuti i costi computazionali, riducendone quindi la rappresentatività. Altri dataset, come quello riguardante i subappalti, sono stati scartati a causa dell'elevata presenza di dati mancanti, che ne avrebbe limitato l'utilità nella costruzione di indicatori informativi e discriminanti.

Un'altra fase importante ha riguardato il preprocessing, reso necessario dalla presenza diffusa di valori nulli, errori di codifica e inconsistenze formali. Si è proceduto alla sistemazione delle variabili critiche e alla pulizia delle denominazioni delle stazioni appaltanti, correggendo inoltre alcuni codici fiscali errati o duplicati e recuperando, dove possibile, le informazioni mancanti.

Struttura finale del dataset

Il dataset finale è composto da oltre 10 milioni di osservazioni e 57 variabili, dove ogni riga rappresenta un'unità composta da bando, aggiudicazione e aggiudicatario. Ciò comporta che una stessa gara possa comparire più volte nel caso in cui presenti più lotti o più soggetti aggiudicatari, una scelta strutturale che permette di preservare il dettaglio informativo necessario per analisi accurate ed evitare aggregazioni improprie di situazioni diverse. Il risultato di queste operazioni è un dataset coerente e strutturato, che fornisce una base solida per l'analisi del rischio tramite metodi di anomaly detection e per la successiva generazione delle red flag.

Calcolo delle red flag

Abbiamo deciso di adottare nel nostro lavoro il sistema di indicatori di rischio sviluppato dall'ANAC nell'ambito del progetto "Misurazione del rischio di corruzione" [1]. In lavori di questo tipo infatti la corruzione va considerata a tutti gli effetti un costrutto latente e come tale non è misurabile direttamente, dunque risulta appropriato fornirsi di un insieme di misurazioni. I singoli indicatori, detti anche red flag, sono costruiti ognuno con l'obiettivo di misurare un singolo aspetto del rischio corruttivo; nel complesso, l'unione di questi indicatori può quindi essere interpretata come una descrizione della corruzione latente. Inoltre, come si può leggere nella scheda dell'A-

NAC, ogni red flag è il risultato di numerosi studi specialistici volti a massimizzare l'efficacia nell'individuazione dei casi sospetti, anche se mancano ancora validazioni solide da un punto di vista statistico.

È importante notare che gli indicatori dell'ANAC sono pensati per essere calcolati su più appalti, ovvero ognuno fornisce una misura di un aspetto del rischio corruttivo all'interno di un determinato gruppo di bandi: significa che in uno studio come questo non è possibile lavorare su appalti singoli, a meno di cambiare totalmente il metodo di analisi. Abbiamo deciso quindi di aggregare gli appalti per stazione appaltante, con l'obiettivo di individuare le stazioni più anomale sulla base di tutti i bandi pubblicati dalle stesse. Inoltre, per poter calcolare gli indicatori dobbiamo avere a disposizione almeno 2 bandi di appalto per stazione, quindi siamo costretti a eliminare tutte quelle che hanno solo 1 bando associato che risultano essere 3722 su un totale di 37375, pari a circa il 10%.

In totale il sistema di indicatori è composto da 17 red flags. Le informazioni necessarie per poterle calcolare sono localizzate in diversi dataset pubblici disponibili sul sito web dell'ANAC; come abbiamo spiegato nel paragrafo precedente, per motivi di dimensione dei dati non è stato possibile includere all'interno del nostro dataset dei bandi le informazioni richieste per tutti gli indicatori, quindi abbiamo scelto di restringere il sistema a 13 indicatori. Di seguito elenchiamo nel dettaglio quali sono gli indicatori che abbiamo valutato e come li abbiamo calcolati. (N.B.: Gli indici numerici corrispondono a quelli contenuti nella scheda dell'ANAC).

1. Offerta economicamente vantaggiosa

L'indicatore prende in considerazione il criterio di aggiudicazione degli appalti, ovvero cos'ha spinto una stazione ad affidare un appalto a una specifica azienda tra quelle che hanno presentato un'offerta. Viene calcolato come la proporzione di appalti aggiudicati in base al criterio del minor prezzo sul totale dei bandi con criterio definito (ovvero non mancante) pubblicati da una determinata stazione. Ci permette quindi di misurare quanto spesso la stazione ricorre al criterio del minor prezzo rispetto a criteri tendenzialmente preferibili come il rapporto qualità/prezzo.

2. Numero delle procedure non aperte

Per calcolare questo indicatore abbiamo deciso di aggregare i tipi di procedura dei bandi in 5 categorie: affidamento diretto, procedura negoziata, procedura aperta, dialogo competitivo, partenariato. Bisogna calcolare per ogni stazione la proporzione di bandi con affidamento diretto o procedura negoziata sul totale dei bandi con tipo di procedura definito.

3. Valore delle procedure non aperte

Viene calcolato, per ogni stazione, come il rapporto tra il valore totale in euro degli appalti affidati mediante affidamento diretto o procedura negoziata e il valore complessivo di tutti gli appalti con tipologia di procedura definita. È quindi analogo al precedente, ma basato sul valore economico delle procedure non aperte invece che sul loro numero.

4. Contratti aggiudicati e modificati per effetto di almeno una variante

Per ogni stazione viene calcolata la proporzione di appalti conclusi che in fase di esecuzione sono stati interessati da almeno una variante sul numero totale di appalti conclusi.

5. Scostamento dei costi di esecuzione

È la media dei rapporti tra il costo effettivo dell'appalto e il costo preventivato. L'informazione sul costo effettivo viene ottenuta sommando gli importi di lavori, servizi, forniture e progettazione indicati al termine dell'appalto; il costo preventivato è invece già disponibile. È importante notare che non vengono considerati gli appalti ancora in corso, poiché il costo effettivo di questi non è definitivo.

7. Inadempimento delle comunicazioni di aggiudicazione

Secondo le indicazioni dell'ANAC bisognerebbe calcolare la proporzione di bandi per cui non è stata comunicata la scheda di aggiudicazione sul totale dei bandi per i quali la scheda doveva essere comunicata. Nella pratica cerchiamo di ottenere lo stesso risultato calcolando la proporzione di bandi con esito mancante (stringa vuota) sul numero totale di bandi, dal momento che non siamo in grado di stabilire per quali bandi era necessario comunicare l'aggiudicazione.

9. Offerta singola

Secondo la teoria dobbiamo calcolare la proporzione di bandi con una sola offerta ammessa sul totale di bandi pubblicati. Il reperimento delle informazioni tuttavia non è semplice, a causa di diffuse incongruenze nei dati. Per il numero di offerte ammesse usiamo la variabile `numero_offerte_ammesse` quando questa non è 0, e in caso contrario la sostituiamo col numero di aggiudicatari, ottenuto contando quanti aggiudicatari risultano per ciascun appalto; questo ci permette di avere una stima approssimata del numero reale di offerte ammesse, anche se c'è una buona probabilità che sia sottostimato. In modo analogo, per il numero di offerte totali usiamo `num_imprese_offerenti` quando questa non è 0, e in caso contrario la sostituiamo col numero di partecipanti, perdendo però i possibili casi in cui una stessa azienda ha presentato più offerte. Con queste approssimazioni capita in alcuni casi che il numero di offerte ammesse risulti maggiore del numero di offerte totali; questo chiaramente non è realistico, quindi in questi casi alziamo il valore della prima in modo che sia pari alla seconda.
Tutte queste approssimazioni ci permettono di calcolare l'indicatore come il rapporto tra il numero di casi in cui il numero di offerte ammesse e di offerte totali sono entrambe uguali a 1 e il numero di casi in cui queste sono diverse da 0. Ci aspettiamo che sia uno dei migliori indicatori per la rilevazione delle anomalie, dal momento che una carenza di competizione è associata a un alto rischio di corruzione.

10. Proporzione di offerte escluse

L'indicatore ha l'obiettivo di misurare la carenza di competizione. Per ogni stazione va calcolata la media aritmetica del rapporto tra numero di offerte escluse sul numero di offerte presentate. Nella pratica, la logica ci suggerisce di calcolare tutti i rapporti tra il numero di offerte ammesse e il numero di offerte totali (definite per l'indicatore precedente), dopodiché calcolarne il complementare (uno meno i rapporti, che sono proporzioni) e infine applicare la media.

11. Esclusione di tutte le offerte tranne una

Come il precedente indicatore, misura la mancanza di competizione: è la proporzione di bandi per cui sono state escluse tutte le offerte tranne una sul totale dei bandi con una sola offerta ammessa. Calcoliamo per ogni stazione il rapporto tra il numero di bandi con 1 offerta ammessa ma almeno 2 offerte presentate e il numero di bandi con 1 offerta ammessa.

12. Proporzione di offerte escluse in procedure con tutte le offerte escluse tranne una

È una variante dell'indicatore 10, con la differenza che vengono considerati solo i bandi che hanno una sola offerta ammessa a fronte di un numero di offerte presentate maggiore di 1.

13. Proporzione di contratti aggiudicati alla stessa azienda

L'indicatore dà una misura di quanto una certa stazione appaltante affidi in modo sistematico gli appalti a un numero ristretto di aziende. Per ogni stazione bisogna calcolare la proporzione di bandi affidati a ciascuna azienda; da questa distribuzione si ricava l'omogeneità,

ottenuta invertendo l'indice di eterogeneità di Gini normalizzato. Va notato che questo indicatore così calcolato non è limitato superiormente: con distribuzione perfettamente uniforme (eterogeneità nulla) otteniamo un'omogeneità che tende a infinito, mentre nel caso contrario di massima concentrazione (eterogeneità unitaria) si ottiene un'omogeneità pari a 1.

14. Estensione del periodo di pubblicazione del bando (tra pubblicazione del bando e data di scadenza sottomissione proposte)

L'indicatore misura l'estensione temporale che intercorre tra la data di pubblicazione del bando e la data di scadenza per la presentazione delle offerta, calcolato per ogni stazione appaltante come la media di tutte le singole differenze in giorni.

15. Estensione del periodo di valutazione dell'offerta (tra data offerta e data aggiudicazione) per procedura di gara

L'indicatore misura l'estensione temporale che intercorre tra la data di presentazione delle offerte da parte delle aziende e la data di aggiudicazione del contratto da parte della stazione appaltante. In modo analogo al precedente, va calcolata la media di tutte le singole differenze in giorni.

Per costruzione, valori alti degli indicatori con indice 1, 2, 3, 4, 7, 9, 10, 11, 12 sono associati a un rischio di corruzione maggiore; vale l'inverso per gli indicatori 5, 13, 14 e 15: per il 5 il caso meno rischioso è il valore 1 o secondariamente tra 0 e 1, mentre valori molto più grandi di 1 indicano un potenziale rischio; per il 13 valori di omogeneità tendenti a 1 (tutti gli appalti affidati a una sola azienda) sono segnali di rischio; per 14 e 15 estensioni temporali ristrette (poco tempo per presentare e valutare le offerte) possono segnalare comportamenti illeciti.

Abbiamo scelto di tralasciare le 4 red flag seguenti: "Scostamento dei tempi di esecuzione" (6) avrebbe richiesto troppe approssimazioni a fronte di un indicatore non particolarmente importante; per "Inadempimento delle comunicazioni di fine lavori" (8) non siamo stati in grado di reperire con adeguata precisione le informazioni necessarie; "Addensamento sotto soglia v1" (16) e 'Addensamento sotto soglia v2" (17) sono probabilmente dei buoni indicatori, ma il loro calcolo richiede anche i dati relativi ai bandi con procedura agevolata (SmartCIG) che sono stati esclusi per le ragioni descritte nel paragrafo sul reperimento dei dataset.

Abbiamo deciso inoltre di aggiungere alcune variabili per cogliere ulteriori aspetti degli appalti. Sono calcolate sempre per stazione appaltante e possono agire sia come variabili di regolazione sia come indicatori di rischio aggiuntivi; d, e, f sono pensate per tenere conto di inadempienze e mancanze di informazioni fondamentali. Le identifichiamo tramite lettere minuscole:

a) **Numero totale di appalti**, ottenuto contando gli appalti per stazione;

b) **Numero di appalti con affidamento diretto**, ottenuto contando gli appalti con affidamento diretto per stazione;

c) **Valore totale delle gare**, calcolato come la somma dei singoli valori in euro degli appalti offerti da ogni stazione;

d) **Proporzione di appalti con criterio di aggiudicazione mancante**;

e) **Proporzione di appalti con numero di offerte mancante**;

f) **Proporzione di appalti con importo complessivo mancante**;

g) **Proporzione di bandi con data di aggiudicazione definitiva precedente alla data di scadenza del bando**, indicatore di un'anomalia che abbiamo notato e che può essere rilevante.

Leggendo la Tabella 1 si nota che in molti casi i valori calcolati degli indicatori risultano

Nome variabile	Corrispondenza	% valori non validi	Mantenuta
num_appalti	Variabile a	0	SÌ
num_appalti_diretti	Variabile b	68.6	SÌ
val_tot	Variabile c	6.7	SÌ
prop_na_criterio_aggiudicazione	Variabile d	0	SÌ
prop_na_offerte_ammesse	Variabile e	0	SÌ
prop_na_importo_gara	Variabile f	0	SÌ
prop_date_contrarie	Variabile g	12.9	SÌ
offerta_econo_vant	Indicatore 1	12.9	SÌ
num_proc_non_aperte	Indicatore 2	1.27	NO
val_proc_non_aperte	Indicatore 3	0.03	SÌ
contr_almeno_una_var	Indicatore 4	45.7	SÌ
scostamento_costi	Indicatore 5	57	SÌ
inademp_comun_aggiudicazione	Indicatore 7	0	SÌ
offerta_singola	Indicatore 9	30.6	SÌ
prop_offerte_escluse	Indicatore 10	30.6	SÌ
escl_tutte_tranne_una	Indicatore 11	37.2	SÌ
prop_offerte_escluse_12	Indicatore 12	75.3	NO
prop_contr_stessa_azienda	Indicatore 13	33.2	SÌ
mean_diff_date1	Indicatore 14	0.04	SÌ
mean_diff_date2	Indicatore 15	12.9	SÌ
calcolabile1 ... calcolabile15	Singole flag calcolabili	0	NO
calcolabile_tot	Num. flag calcolabili	0	SÌ

Tabella 1: Corrispondenza tra variabili nella tabella finale e significato reale, con percentuale di valori non validi.

mancanti o problematici (ad esempio infiniti o NaN). Questo è dovuto principalmente a due motivi: mancanza di dati di partenza (e quindi inadempienze importanti da parte delle stazioni appaltanti da considerare) oppure motivi legati alla natura intrinseca degli indicatori (ad esempio, red flag che considerano solo appalti già terminati non possono essere calcolate per stazioni che hanno solo appalti in corso). Sulla base delle percentuali nella tabella decidiamo di porre 70% di dati problematici come soglia di eliminazione di una variabile, e di conseguenza escludiamo l'indicatore 12. Per tutte le altre variabili rimanenti, procediamo nel modo seguente per risolvere i valori problematici:

- Creiamo un set di variabili dicotomiche, una per ogni indicatore di rischio dell'ANAC, chiamate `calcolabileX`, dove al posto di `X` si trova l'indice dell'indicatore al quale fa riferimento. Queste assumono valore 1 se l'indicatore è stato calcolato correttamente e valore 0 altrimenti. Inoltre, creiamo la variabile `calcolabile_tot` che, calcolata sommando le singole dicotomiche, indica quante red flag sono calcolabili per ogni stazione.

- Poiché le variabili dicotomiche precedenti descrivono con precisione gli errori di calcolo delle red flag, i valori mancanti o problematici degli indicatori vengono imputati scegliendo valori a minimo impatto sulla rilevazione delle anomalie; in assenza di informazioni, si assume quindi lo scenario di minor rischio coerente con il funzionamento degli indicatori esplicitato poco sopra. Per questo, nelle variabili da noi introdotte e negli indicatori 1, 2, 3, 4, 9, 10, 11 imputiamo 0; nell'indicatore 5 imputiamo 1; gli indicatori 13, 14, 15 sono limitati inferiormente (caso più rischioso) ma non superiormente, quindi scegliamo di imputare la loro mediana.

Come ultima considerazione, abbiamo scelto di escludere l'indicatore 2 (numero delle

procedure non aperte) in quanto la sua distribuzione risulta fortemente spostata su valori prossimi a 1, che per costruzione dovrebbero corrispondere alla condizione di maggiore rischio, mentre sono poco rappresentati i valori prossimi a 0. Il suo mantenimento potrebbe quindi generare un effetto distorsivo, attribuendo un peso eccessivo a situazioni non necessariamente anomale e producendo un impatto opposto a quello desiderato nella rilevazione delle criticità.

Inoltre, per i motivi che verranno approfonditi nei paragrafi successivi, i modelli di anomaly detection che abbiamo scelto non sono adatti a lavorare con variabili categoriali, dunque abbiamo valutato di eliminare le singole `calcolabileX` per mantenere solo `calcolabile_tot` che corrisponde alla loro somma.

Al termine di questa fase otteniamo un dataset con 33653 righe, corrispondenti ad altrettante stazioni appaltanti, e 21 colonne, due delle quali sono codice fiscale e denominazione della stazione appaltante. La Tabella 1 riassuntiva contiene i nomi che sono stati assegnati agli indicatori e alle variabili calcolate; la colonna "Mantenuta" indica quali variabili hanno superato questa fase di controllo e sono quindi presenti nel dataset finale.

Metodi

Per la parte più tecnica di questa analisi, in questo capitolo verranno presentati i due modelli utilizzati per l'analisi del rischio di corruzione nelle stazioni appaltanti. L'intero lavoro si colloca in un contesto di apprendimento non supervisionato, poiché non disponiamo di informazioni affidabili che permettano di stabilire, per ogni stazione appaltante, se vi sia stata effettivamente corruzione oppure no. In assenza di una variabile risposta, non è quindi possibile costruire un modello predittivo tradizionale. L'obiettivo diventa invece quello di individuare comportamenti anomali nei dati e, a partire da questi, costruire una classifica delle stazioni appaltanti in base al loro livello di rischio potenziale, utilizzando gli indicatori descritti nel capitolo precedente.

Per affrontare questo problema, abbiamo scelto di utilizzare due modelli differenti di anomaly detection: Autoencoder e Isolation Forest. La scelta di adottare entrambi nasce dalla volontà di combinare punti di forza complementari. L'autoencoder è un modello basato su reti neurali particolarmente efficace nell'individuare strutture complesse nei dati e relazioni non lineari tra le variabili. Questo lo rende uno strumento molto potente quando si analizzano fenomeni articolati come quelli legati agli appalti pubblici, dove le anomalie possono emergere da combinazioni di indicatori difficili da individuare con metodi più semplici. Tuttavia, il principale limite di questo approccio riguarda l'interpretabilità, poiché il modello riesce a segnalare quali osservazioni risultano anomale, ma spiegare con chiarezza le ragioni di tale classificazione risulta meno immediato.

Accanto all'autoencoder abbiamo quindi utilizzato anche l'Isolation Forest, un algoritmo non supervisionato semplice dal punto di vista strutturale, ma che a livello di interpretabilità tramite SHAP risulta più esaustivo e meno costoso a livello computazionale (maggiori dettagli per SHAP sono contenuti nel paragrafo *SHAP*). Il modello identifica le anomalie isolando più rapidamente le osservazioni che presentano caratteristiche insolite rispetto al resto del dataset, offrendo quindi una lettura più immediata dei risultati.

L'utilizzo congiunto di questi due approcci permette di ottenere un'analisi più solida: da un lato, l'autoencoder consente di catturare pattern complessi che potrebbero sfuggire a modelli più tradizionali; dall'altro, l'Isolation Forest fornisce un ulteriore livello di controllo e una visione più ampia nel campo dell'interpretazione. In questo modo è possibile costruire una classifica più robusta delle stazioni appaltanti e, allo stesso tempo, fornire indicazioni più chiare sui fattori che contribuiscono al rischio di anomalia.

Preparazione dei dati

Durante le prime analisi preliminari è emerso il fatto che, considerando tutte le stazioni appaltanti come un unico gruppo, tra le osservazioni più anomale comparivano frequentemente comuni e istituzioni scolastiche. Questo risultato, però, non sembrava riflettere necessariamente un rischio più elevato di corruzione, quanto piuttosto una differenza strutturale nelle caratteristiche delle gare gestite da queste categorie. Approfondendo i dati, è emerso infatti che comuni e istituzioni scolastiche tendono a pubblicare bandi con caratteristiche diverse rispetto alla maggior parte delle altre stazioni appaltanti. Di conseguenza, i modelli tendevano a classificarli come anomali semplicemente perché lontani dal comportamento medio del resto del campione, generando quindi anomalie dovute alla composizione del dataset e non a reali segnali di rischio.

Per ridurre questo problema, si è deciso di svolgere analisi separate per entrambi i modelli, suddividendo le stazioni appaltanti in tre gruppi distinti:

- Comuni: 8.036 stazioni.
- Istituzioni scolastiche: 8.136 stazioni.
- Altre stazioni appaltanti: 17.481 stazioni.

per un totale complessivo di 33.653 stazioni appaltanti. Questa suddivisione consente di confrontare ogni stazione appaltante con realtà più simili tra loro, rendendo l'identificazione delle anomalie più coerente e meno influenzata da differenze strutturali tra categorie molto eterogenee.

Prendendo come esempio il gruppo "altro", che comprende tutte le stazioni appaltanti escluse dai primi due gruppi, dopo aver selezionato le osservazioni appartenenti a questa tipologia, viene effettuata una fase iniziale di preprocessing sulle variabili numeriche. In particolare, le variabili che presentavano valori al di fuori dell'intervallo [0,1] sono state normalizzate, così da rendere tutte le feature confrontabili sulla stessa scala ed evitare che variabili con valori numericamente più elevati influenzassero in modo eccessivo i modelli. La normalizzazione è stata effettuata tramite Min-Max scaling, ma con un accorgimento aggiuntivo per gestire la presenza di valori estremi. Alcune osservazioni presentavano infatti valori particolarmente elevati, spesso poco plausibili e probabilmente dovuti a errori di compilazione o registrazione dei dati, i quali, se mantenuti invariati, avrebbero compresso eccessivamente la distribuzione delle altre osservazioni, riducendo la capacità discriminativa delle variabili. Per evitare questo problema, è stata applicata una procedura di clipping in cui tutti i valori inferiori al primo quantile sono stati sostituiti con il valore del primo quantile, e analogamente per i valori superiori all'ultimo quantile. Al termine di questo processo, tutte le variabili risultano comprese tra 0 e 1, rendendo i dati più omogenei e permettendo ai modelli di attribuire un peso più equilibrato ai diversi indicatori.

Isolation Forest

L'Isolation Forest[9] è un algoritmo di anomaly detection non supervisionata utilizzato per individuare osservazioni che presentano comportamenti anomali rispetto alla maggioranza del dataset. Si basa sull'idea per cui le anomalie sono generalmente più rare e più diverse rispetto alle osservazioni normali e, proprio per questo motivo, tendono a essere più facili da isolare.

Il funzionamento dell'algoritmo si basa sulla costruzione di un insieme di alberi decisionali casuali, per cui per ogni albero viene selezionato casualmente un sottoinsieme dei dati e, successivamente, vengono effettuate suddivisioni casuali scegliendo ogni volta una variabile e un valore di soglia. Questo processo continua finché le osservazioni vengono progressivamente separate tra loro.

Come mostrato in figura 1,le osservazioni considerate normali tendono a richiedere un numero maggiore di suddivisioni prima di essere isolate, poiché si trovano in aree dense del dataset e condividono caratteristiche simili con molte altre unità. Al contrario, le osservazioni anomale, essendo più isolate già

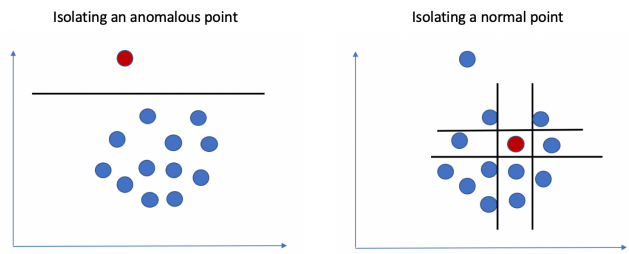

Figura 1: Isolation forest idea

in partenza, vengono separate in un numero minore di passaggi. In termini pratici, il modello misura quindi la profondità media di isolamento di ogni osservazione nei diversi alberi, dove una profondità minore corrisponde a una maggiore probabilità che l'osservazione sia anomala.

Una volta addestrato il modello sui dati preprocessati, per ogni stazione appaltante viene calcolato un anomaly score, che rappresenta una misura del grado di anomalia dell'osservazione. Valori più bassi indicano una maggiore anomalia.

Successivamente, questi risultati vengono integrati con le informazioni identificative delle stazioni appaltanti, come codice fiscale e denominazione, e con i valori originali degli indicatori. Questo passaggio consente di costruire una classifica delle stazioni appaltanti più anomale e di analizzare nel dettaglio i casi con i punteggi peggiori, in modo da capire meglio i fattori che ne hanno causato la posizione nella classifica.

L'Isolation Forest rappresenta quindi un metodo particolarmente utile in questo contesto perché combina semplicità ed efficienza computazionale. Nel prossimo capitolo, invece, verrà mostrato come sfruttare SHAP per ottenere una più esaustiva interpretabilità dei suoi risultati.

Autoencoder

L'autoencoder[8] è una tecnica basata su reti neurali che può essere utilizzata anche per l'anomaly detection, in cui il modello viene addestrato a ricostruire i dati considerati normali, apprendendone le caratteristiche principali e comprimendo l'informazione in una rappresentazione più compatta, come mostrato in figura 2. In fase di test, quando viene fornito un dato, l'autoencoder tenta di ricostruirlo e se il dato è stato ben imparato durante l'addestramento, la ricostruzione risulterà accurata; al contrario, se il dato è anomalo o molto diverso rispetto ai pattern appresi, l'errore di ricostruzione sarà più elevato. In questo contesto, un errore di ricostruzione elevato può quindi rappresentare un segnale della presenza di un'anomalia, rendendo questo approccio particolarmente utile per individuare comportamenti insoliti o fuori standard.

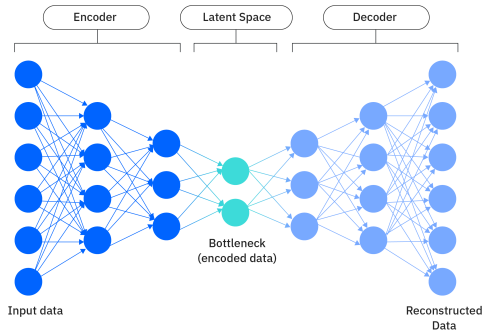

Figura 2: Autoencoder idea

A differenza dell'Isolation Forest, l'autoencoder non si limita a identificare singoli valori anomali o outlier, ma è in grado di cogliere anche relazioni più complesse tra le variabili. Questa caratteristica è particolarmente rilevante per la nostra analisi, poiché ci aspettiamo che il rischio di corruzione non emerga tanto da singoli valori estremi, quanto piuttosto da combinazioni anomale tra più variabili.

Poiché l'obiettivo dell'analisi di anomaly detection è costruire una classifica delle stazioni appaltanti in base al loro potenziale grado di rischio corruttivo, e dato che ci troviamo in un contesto non supervisionato, è possibile addestrare l'autoencoder sull'intero dataset e successivamente valutarne la capacità di ricostruzione sugli stessi dati. In questo caso, infatti, non interessa utilizzare il modello per generalizzare su stazioni appaltanti non presenti nel dataset, ma ottenere una misura relativa del livello di anomalia all'interno dei

dati osservati. La classifica sarà quindi definita tramite la media degli errori di ricostruzione al quadrato per ogni stazione, penalizzando in questo modo maggiormente errori più grandi. Nel caso in cui in futuro si vogliano aggiornare i dati, sarà sufficiente riaddestrare il modello sul nuovo dataset, operazione che risulta relativamente rapida dal punto di vista computazionale.

La classifica ottenuta rimane comunque affidabile anche se il modello viene addestrato su dati che potrebbero contenere alcune anomalie. Si presume infatti che tali anomalie rappresentino una quota limitata rispetto al totale delle osservazioni e di conseguenza, il modello apprenderà prevalentemente i pattern normali e ricostruirà meglio le situazioni ordinarie, mentre le osservazioni più anomale presenteranno errori di ricostruzione più elevati e verranno quindi posizionate più in alto nella classifica di rischio.

L'architettura scelta per l'autoencoder prevede 7 layer e un bottleneck relativamente largo in modo da catturare meglio le possibili anomalie meno evidenti, ottenendo così una configurazione sufficientemente complessa da catturare relazioni articolate tra le variabili, ma non così profonda da causare fenomeni di overfitting. Per ridurre ulteriormente questo rischio sono state applicate tecniche di regolarizzazione, come dropout e regolarizzazione ridge, che introducono sia un elemento di casualità sia un vincolo sulla complessità del modello, favorendo una maggiore capacità di generalizzazione.

Considerando sia la natura dei dati sia l'incertezza introdotta dalle tecniche di regolarizzazione, per ottenere risultati più robusti è necessario ripetere il processo di training e testing più volte. Si è quindi scelto di eseguire 10 round di addestramento, cosa che non causa problemi dal punto di vista computazionale, dal momento che ogni round impiega circa 1 min di tempo di calcolo. Ad ogni round, il modello produce una classifica delle stazioni appaltanti e per ogni stazione viene poi calcolata la media delle posizioni ottenute nei diversi round, escludendo quella migliore e quella peggiore per limitare l'influenza di risultati particolarmente estremi sul posizionamento finale.

SHAP

Come si è visto, i modelli da noi adottati sono detti *black-box*, poiché di per sé non forniscono alcuna interpretazione dei risultati e non permettono di spiegare l'effetto delle variabili sul posizionamento finale nella classifica di anomalia.

Di fronte alla crescente esigenza di interpretare i risultati dei modelli, il settore dell'*Explainable AI* sta assumendo un ruolo sempre più centrale nella ricerca. Uno degli avanzamenti più significativi in questo ambito è rappresentato dal metodo SHAP (*SHapley Additive exPlanations*), basato sugli *Shapley values* sviluppati all'interno della teoria dei giochi [11] e adattati per consentire di interpretare in modo coerente e teoricamente fondato le decisioni di modelli complessi di machine learning. In particolare, gli SHAP attribuiscono a ciascuna variabile un contributo quantitativo alla predizione (nel nostro caso del punteggio di anomalia), permettendo di scomporre l'output del modello in effetti individuali delle variabili. Questo approccio garantisce proprietà desiderabili come consistenza e additività, rendendo le spiegazioni comparabili e affidabili [10]. Nella sezione successiva sfrutteremo questo metodo per interpretare i risultati dell'Isolation Forest e valutare l'effetto delle variabili sul punteggio di anomalia.

Per quanto riguarda l'autoencoder, a causa della maggiore complessità del modello non è altrettanto immediato calcolare i valori SHAP per analizzare l'effetto delle singole variabili; infatti, il loro calcolo per modelli così complessi è estremamente gravoso dal punto di vista computazionale e richiede capacità computazionali molto elevate. Abbiamo provato ad applicare un approccio alternativo, sempre basato su SHAP, che avrebbe permesso di interpretare a posteriori le ragioni per cui una specifica stazione è risultata anomala, come descritto nell'articolo *Explaining anoma-*

lies detected by autoencoders using Shapley Additive [7]. Tuttavia, anche a seguito di alcune modifiche sostanziali al codice fornito non siamo stati in grado di estrarre risultati stabili, a conferma della grande complessità del modello e della difficoltà intrinseca di interpretazione. Il codice di questa procedura è comunque disponibile nella repository all'interno del file `ExplainSHAP.py`.

Risultati e interpretazioni

Come già spiegato nella sezione precedente, abbiamo costruito un modello di Isolation Forest per poter valutare tramite SHAP l'effetto delle variabili sul punteggio di anomalia predetto. Con i dati divisi in 3 parti per tipo di stazione appaltante (comuni, scuole, tutto il resto) possiamo studiare l'impatto delle variabili separatamente in ciascun gruppo.

I grafici nelle Figure 3, 4, 5 mostrano i valori SHAP calcolati per ogni variabile. Le variabili sono ordinate in base alla loro importanza nella predizione dell'anomalia; inoltre, è possibile osservare la forma della relazione tra ciascuna variabile e il punteggio di anomalia. Se una variabile passa dal rosso al blu da sinistra a destra (idealmente con separazione sul valore 0 di SHAP) significa che esiste una relazione monotona positiva tra la variabile e il punteggio di anomalia, ovvero all'aumentare del valore di quella variabile aumenta anche il rischio di anomalia: infatti, SHAP negativi indicano maggior propensione all'anomalia. Al contrario, una variabile che passa dal blu al rosso indica che il rischio di anomalia diminuisce con l'aumentare della variabile. Tra questi due estremi si possono avere tutti i tipi di effetti non lineari, segnalati dall'alternanza tra colori nel grafico.

È di nostro interesse studiare la rilevanza e l'efficacia degli indicatori dell'ANAC nella rilevazione delle anomalie: infatti, una volta accertati gli indicatori più importanti e la loro affidabilità questi possono essere utilizzati con maggior consapevolezza in fase di indagine.

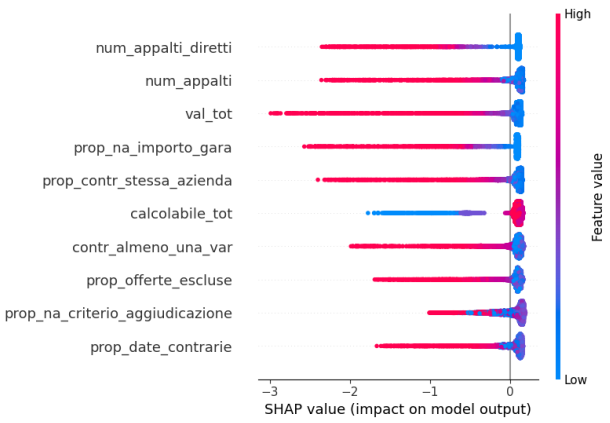

Figura 3: SHAP per comuni.

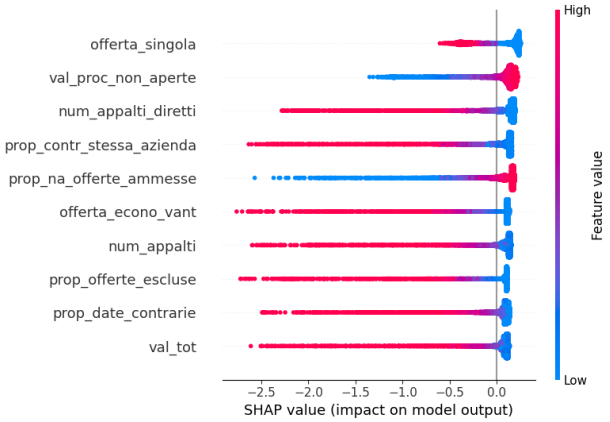

Figura 4: SHAP per scuole.

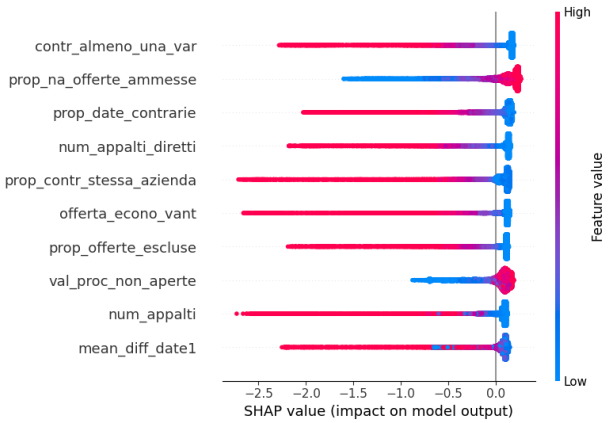

Figura 5: SHAP per altre stazioni (no scuole, no comuni).

A prima vista emerge come l'indicatore 13 (proporzione di contratti assegnati alla stessa azienda) risulti molto importante per tutti e 3 i tipi di stazione ma in modo inverso

rispetto alle attese, dal momento che secondo il grafico valori maggiori sono associati a un rischio maggiore di anomalia; per come è costruito l'indicatore a livello teorico l'effetto dovrebbe essere inverso, ma è evidente che calcolando un'omogeneità con limite inferiore a 1 e senza limite superiore si ottengano valori che sono molto più concentrati vicino a 1, che dovrebbe rappresentare invece un rischio maggiore: in sostanza, possiamo affermare che questo indicatore non sia valido in questa forma e richieda un ripensamento per renderlo utilizzabile.

Considerazioni analoghe valgono anche per l'indicatore 3 che sulla base dei grafici risulta avere un comportamento opposto rispetto alle attese. In questo caso è probabile che la causa sia il ricorso molto diffuso da parte delle stazioni appaltanti a bandi con procedura non aperta, che ha come conseguenza la rarefazione dei valori bassi dell'indicatore e la concentrazione verso valori alti (in modo simile a quanto accadeva con l'indicatore 2 che è stato escluso nelle fasi precedenti e che si riferiva al numero di procedure non aperte).

Escludendo quindi gli indicatori 3 e 13, per quanto riguarda i comuni possiamo notare che tra le prime 10 variabili compaiono in ordine gli indicatori 4 (proporzione di contratti con almeno una variante) e 10 (proporzione di offerte escluse); per entrambi questi indicatori valori alti sono associati a un rischio di anomalia maggiore, in modo conforme alle attese. Spostandoci sulle scuole, in ordine notiamo gli indicatori 9 (offerta singola, tra l'altro al primo posto), 1 (offerta economicamente vantaggiosa) e 10, tutti e 3 associati in modo positivo al rischio di anomalia come era atteso. Infine, per il resto delle stazioni si leggono in ordine gli indicatori 4, 1, 10 e 14 (estensione del periodo di pubblicazione del bando); mentre i primi 3 continuano a mostrare l'effetto atteso, per il 14 questo sembra essere più complicato. Per questa variabile può essere quindi utile osservare più nel dettaglio la forma del suo effetto tramite il grafico in Figura 6. Per sua costruzione, questo indicatore dovrebbe segnalare un maggior rischio di corruzione per valori bassi. Dal grafico notiamo che si ha un rischio maggiore per valori bassi dell'indicatore e in particolar modo per valori alti, ma bisogna tenere conto che in molti casi il valore calcolato è negativo (per l'esattezza in 3545 casi) a causa delle anomalie colte anche con una variabile apposta come spiegato nella sezione delle red flag, quindi sembra che il rischio maggiore si abbia per valori negativi o abbastanza grandi; per questo, riteniamo che questo non sia un indicatore affidabile da calcolare.

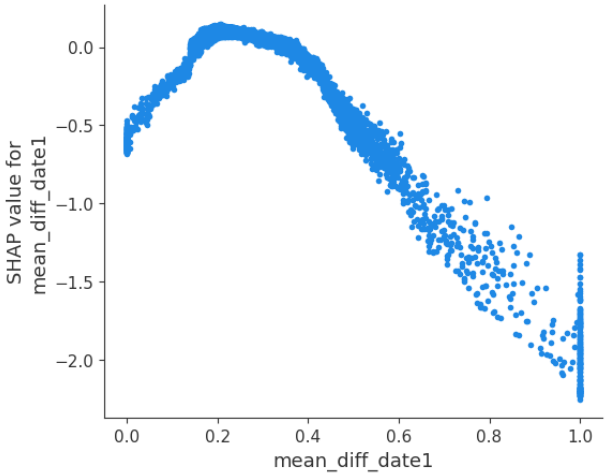

Figura 6: SHAP per la variabile `mean_diff_date1` nelle altre stazioni (no scuole, no comuni).

Passando invece alle variabili da noi introdotte, si nota come le 3 variabili legate al numero totale di appalti, al numero di appalti ad affidamento diretto e il valore totale abbiano un'importanza diffusa in tutti e 3 i tipi di stazione. È importante però ricordare che sono da intendere come variabili di contesto e non indicano alcun nesso causale; in questo senso, ci limitiamo a constatare come tendenzialmente le stazioni più anomale siano anche quelle più grandi, che pubblicano più bandi dal valore economico maggiore.

La variabile `calcolabile_tot` relativa al numero di indicatori dell'ANAC calcolabili risulta tra le prime 10 per importanza solo per i comuni, e come ci si aspettava più basso è il numero di red flag calcolabili, maggiore è il rischio di anomalia. Sempre per quanto ri-

guarda le inadempienze, per i comuni risulta rilevante anche la variabile f (proporzione di bandi con importo mancante); notiamo anche la variabile d al nono posto (proporzione di bandi con criterio di aggiudicazione mancante), ma il suo effetto sembra essere complesso e in generale non in linea con le attese. Mentre queste due variabili non compaiono tra le prime 10 degli altri 2 gruppi di stazioni, la variabile e (relativa alla mancanza del numero di offerte ammesse) invece compare negli altri 2 gruppi e non in quello dei comuni. Invece, la variabile g (relativa ai casi in cui la data di aggiudicazione è precedente a quella di scadenza del bando) sembra avere una certa importanza per tutti e 3 i tipi di stazioni, in particolar modo con il terzo gruppo di stazioni rimanenti: risulta infatti che una maggior frequenza di questi casi sia associata a un rischio maggiore di anomalia.

In sostanza, per quanto riguarda gli indicatori dell'ANAC possiamo concludere che in generale i più rilevanti e robusti siano quelli con indice 1, 4, 9 e 10, quindi si può affermare che il rischio di anomalia e quindi idealmente di corruzione sia maggiore quando la stazione appaltante adotta sistematicamente il criterio del miglior prezzo per l'aggiudicazione, approva numerose varianti, aggiudica spesso appalti che hanno avuto una sola offerta o esclude un'alta percentuale di offerte. Al contrario, gli indicatori 2, 3, e 13 si sono dimostrati inaffidabili se non fuorvianti, quindi con queste formulazioni non ci si può basare su frequenza e valore di procedure non aperte né possiamo basarci sui casi di assegnazione sistematica dei bandi allo stesso giro ristretto di aziende, per quanto siano temi rilevanti. L'indicatore 14 ha una invece una natura molto ambigua, e a conti fatti non sembra essere affidabile nella rilevazione del rischio. In ogni caso, come si è visto a seconda del tipo di stazione appaltante è appropriato servirsi di indicatori diversi e dare più peso ad alcuni piuttosto che ad altri.

Integrando queste informazioni con quelle fornite dalle variabili da noi introdotte, possiamo affermare che generalmente le stazioni più propense alla corruzione sono quelle più grandi, e questo vale in particolar modo per i comuni, per i quali abbiamo visto come sia rilevante anche il numero di indicatori dell'ANAC calcolabili. In generale le stazioni più a rischio sono anche quelle a cui mancano più informazioni fondamentali, ad esempio il numero di offerte ammesse e l'importo dell'appalto, oppure in cui risultano alcune stranezze nei dati come la data di aggiudicazione precedente a quella di scadenza delle offerte.

Utilizzo dell'autoencoder

Come abbiamo spiegato nella sezione *Metodi*, riteniamo che l'autoencoder possieda una capacità maggiore di cogliere relazioni non lineari complesse rispetto ad altri modelli come l'isolation forest; per questo motivo, il ranking finale delle anomalie si basa sui suoi risultati.

Data la limitata interpretabilità dell'autoencoder, uno dei pochi approcci utili consiste nell'analizzare gli errori di ricostruzione associati a ciascun indicatore di una determinata stazione appaltante. Questa analisi permette di individuare gli indicatori ricostruiti con maggiore difficoltà, ossia quelli che presentano un errore di ricostruzione più elevato. Un errore elevato suggerisce infatti che tali valori siano considerati anomali dal modello: sulla base dei valori assunti dagli altri indicatori, ci si aspetterebbero valori significativamente diversi nella maggior parte dei casi. Per questo motivo, tali indicatori possono essere interpretati come potenziali anomalie.

Per motivi di privacy non possiamo pubblicare il ranking risultante né possiamo nominare le stazioni appaltanti potenzialmente più corrotte; suggeriamo comunque di selezionare ad esempio l'1% delle stazioni più in alto nella classifica come meritevoli di maggiori attenzioni da parte degli esperti nel settore.

Per studiare la distribuzione geografica del fenomeno abbiamo calcolato la posizione mediana in classifica per ciascuna provincia italiana, considerando solo le prime 1000 stazioni del ranking per i soli comuni in modo da ottenere risultati più robusti. Le prime 3 province per diffusione di anomalie risultano essere in

ordine Reggio Emilia, Trieste, Massa Carrara; in Figura 7 è presente la mappa tematica relativa all'intero Stato italiano (N.B.: le province di Carbonia-Iglesias, Ogliastra, Prato e Bolzano non hanno valori associati perché nessun comune di queste 3 province compare nei primi 1000 comuni).

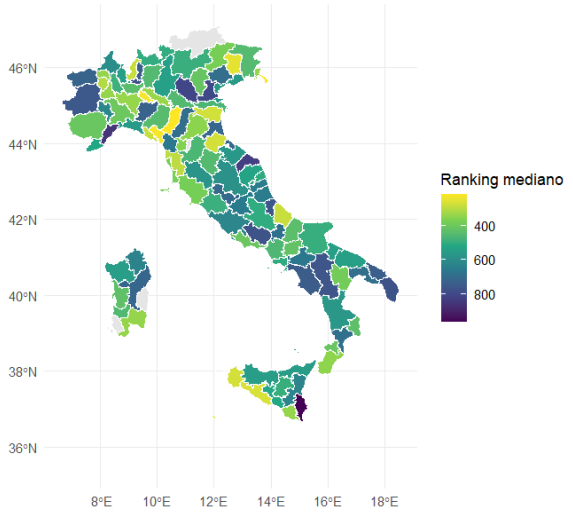

Figura 7: Ranking mediano per provincia (solo i primi 1000 comuni).

Conclusioni

Tramite questo studio abbiamo mostrato un procedimento completo dal reperimento e preprocessing dei dati fino all'ottenimento di risultati concerti, mostrando la potenzialità dell'applicazione dei metodi di anomaly detection sulla rilevazione dei casi di corruzione nei bandi pubblici. Utilizzando i modelli e metodi da noi proposti, abbiamo potuto stabilire le caratteristiche maggiormente sospette delle stazioni appaltanti e stilare una classifica delle stazioni appaltanti per anomalie rilevate.

Sviluppi futuri potrebbero focalizzarsi sul superamento di vari limiti dell'analisi, come il considerare anche i dati che per motivi computazionali abbiamo tralasciato, e con i quali si potrebbero calcolare anche gli indicatori mancanti. Bisognerebbe inoltre approfondire il contenuto dei vari dataset e i motivi dei dati mancanti. Si potrebbe poi valutare l'adozione di metodi differenti di analisi insieme all'approfondimento dei risultati, e considerare un modo per validare i risultati del modello e per valutarne la precisione.

Riferimenti bibliografici

[1] ANAC. Indicatori di rischio corruttivo negli appalti.

[2] ANAC. Banca dati nazionale dei contratti pubblici: Manuale di gestione operativa degli open data, September 2023. Versione 1.0.

[3] ANAC. Digitalizzazione dei contratti pubblici, 2024. Ultimo aggiornamento: 28 novembre 2024.

[4] ANAC. Il rischio di corruzione negli appalti. validità degli indicatori, 2024.

[5] ANAC. Open data anac, 2025.

[6] ANAC. Autorità nazionale anticorruzione - sito istituzionale, 2026. Accesso: 20 aprile 2026.

[7] Liat Antwarg, Ronnie Mindlin Miller, Bracha Shapira, and Lior Rokach. Explaining anomalies detected by autoencoders using shapley additive explanations. *Expert systems with applications*, 186:115736, 2021.

[8] Geoffrey E. Hinton and Ruslan R. Salakhutdinov. Reducing the dimensionality of data with neural networks. *Science*, 313(5786), 2006.

[9] Fei Tony Liu, Kai Ming Ting, and Zhi-Hua Zhou. Isolation-based anomaly detection. *ACM Transactions on Knowledge Discovery from Data (TKDD)*, 6(1), 2012.

[10] Scott M Lundberg and Su-In Lee. A unified approach to interpreting model predictions. *Advances in neural information processing systems*, 30, 2017.

[11] Lloyd S Shapley et al. A value for n-person games. 1953.